

GLOBE++: 부분관측 FANET에서 전역 정책 지식의 지역 라우팅 정책 증류홍길동[†], 김철수[‡]**GLOBE++: Global-to-Local Policy Distillation with Predictive Risk Switching for Decentralized FANET Routing**Gildong Hong[†], Chulsoo Kim[‡]**요약**

무인 비행체 애드혹 네트워크(FANET)는 급격한 토폴로지 변화 속에서도 신뢰성 있고 저지연의 라우팅을 유지해야 하며, 자원이 제한된 UAV의 특성상 로컬 정보만을 활용한 분산형 실행이 필수적이다. 전역 정보나 에이전트 간 잦은 제어 메시지 교환에 의존하는 다중 에이전트 강화학습(MARL) 기법들은 우수한 경로를 학습할 수 있으나, 실제 분산 및 이동성 UAV 군집 환경에 배포하기에는 통신 오버헤드와 물리적 제약이라는 배포 격차(Deployment Gap)를 지닌다. 본 논문에서는 전역 그래프 정보를 지닌 교사(Teacher) 모델의 라우팅 정책을 1-hop 로컬 관측 정보만을 사용하는 학생(Student) 모델로 증류하는 정책 증류(Policy Distillation) 기법과, 링크 단절 및 버퍼 위험 상태에서만 예측적 라우팅 분기를 선택적으로 활성화하는 예측적 위험 스위칭(Predictive Risk Switching) 기반의 라우팅 프레임워크인 GLOBE++ Lite-P+를 제안한다. 제안 기법은 평상시에는 가벼운 지리적 라우팅을 수행하여 지연 및 제어 오버헤드를 제어하며, 위험이 감지되는 예외 상황에서만 예측 모델을 구동하여 자원 효율성을 극대화한다. 총 14개 시나리오 및 5개 시드에 대한 시뮬레이션 평가 결과, GLOBE++ Lite-P+의 전신인 Risk-Switch Lite-GLOBE-P 모델이 GPSR, 예측 지리적 라우팅, Evo-QGeo, IQMR Q(λ), DRAMA 및 기존 분산 강화학습 모델 대비 제어 오버헤드 바이트를 현저히 적게 사용하면서도 가장 우수한 패킷 전달율(PDR) 및 전송 기한 준수율을 달성함을 확인하였다.

키워드 : 플라잉 애드혹 네트워크, UAV 라우팅, 지리적 라우팅, 정책 증류, 강화학습, 분산 실행, 라우팅 홀

Keywords : FANET, UAV Routing, Geographic Routing, Policy Distillation, Reinforcement Learning, Decentralized Execution, Routing Holes

ABSTRACT

Flying ad hoc networks (FANETs) require routing decisions that are both reliable under rapid topology changes and executable with only local information on resource-constrained unmanned aerial vehicles (UAVs). Centralized or communication-heavy multi-agent reinforcement learning methods can learn high-quality routing behavior, but their execution-time dependence on global state or inter-agent messages is difficult to deploy in sparse and mobile UAV swarms. This paper presents GLOBE++ Lite-P+, a decentralized routing framework that transfers routing knowledge from a privileged global teacher to a local student and augments the student with predictive risk switching. The teacher is trained offline as a reinforcement-learning actor-critic policy with global topology information, while the deployed policy uses only one-hop candidate features, destination geometry, queue state, predicted link lifetime, onward stability, and lightweight safety gates. The proposed risk switch activates the predictive branch only when the nominal local decision is unsafe, thereby retaining the low-latency behavior of geographic routing in benign cases while improving recovery from routing holes and imminent link breaks. Full Phase 12 experiments over 14 scenarios and five random seeds show that Risk-Switch Lite-GLOBE-P, the fully evaluated predecessor of GLOBE++ Lite-P+, achieves the best overall packet delivery ratio and deadline delivery among GPSR, predictive geographic routing, Evo-QGeo, IQMR Q(λ), DRAMA, and internal Lite-GLOBE variants, while using fewer input bytes than predictive and message-passing RL baselines. The current Phase 13 GLOBE++ Lite-P+ implementation adds link-loss-aware switching, top- k onward stability, energy-aware tie breaking, and drop suppression; its full-scale validation is left as an explicit experimental TODO in this draft.

I. 서론

무인 비행체 애드혹 네트워크(Flying Ad-hoc Network; FANET)는 재난 구조, 군사 작전, 환경 모니터링 등 고정된 통신 인프라가 작동하지 않는 극단적 환경에서 신속하게 임시 통신망을 제공할 수 있는 유망한 기술로 평가받고 있다. 그러나 FANET을 구성하는 무인 항공기(Unmanned Aerial Vehicle; UAV)들은 공중에서 매우 빠른 속도로 불규칙하게 이동하기 때문에 무선 링크 상태가 동적으로 급격히 변화하며, 이로 인해 기존 무선 이동 애드혹 네트워크(MANET)보다 네트워크 토폴로지의 파괴와 형성이 훨씬 더 빈번하게 발생한다. 따라서 이러한 동적 FANET 환경 하에서 종단간 패킷 전달 성능(Packet Delivery Ratio; PDR)을 보장하고 전송 지연을 최소화하는 신뢰성 있는 분산 라우팅 프로토콜 설계는 핵심적인 당면 과제이다.

기존의 대표적인 FANET 라우팅 프로토콜로는 목적지 노드와의 물리적 좌표 거리가 가장 좁혀지는 방향의 이웃 노드로 패킷을 포워딩하는 GPSR(Greedy Perimeter Stateless Routing) [1]과 같은 지리적 라우팅(Geographic Routing) 기법이 널리 채택되어 왔다. 그러나 지리적 라우팅 기법은 장애물이 존재하거나 노드 배치가 불균일한 라우팅 홀(Routing Hole) 지역에 봉착했을 때, 로컬 미니멈(Local Minimum) 문제로 인해 경로 탐색에 실패하고 패킷을 최종 드롭하는 치명적인 취약점을 안고 있다. 이를 보완하기 위해 수치적 지리 진행도와 링크 속도 등을 활용한 예측적 지리적 라우팅 기법들이 고안되었으나, 휴리스틱 매개변수의 조율 한계와 무선 채널의 비정상성(Non-stationarity)으로 인해 복잡하게 우회해야 하는 환경에서는 일반화 성능을 충분히 보증하기 어렵다.

최근 이러한 제약을 기계학습 기반으로 해소하고자 다중 에이전트 강화학습(Multi-Agent Reinforcement Learning; MARL)을 결합한 라우팅 프로토콜이 적극적으로 제안되고 있다. 전역적인 네트워크 연결 상태를 모니터링하는 중앙 집중형 학습 및 분산 실행(Centralized Training and Decentralized Execution; CTDE) 기법들은 우수한 포워딩 행동 궤적을 스스로 학습할 수 있음이 확인되었다. 그러나 이러한 MARL 기법을 실제 제약된 자원의 UAV에 물리적으로 배포하는 단계에서는 심각한 배포 격차(Deployment Gap)가 발생한다. 구체적으로, 전역적인 그래프 주의 네트워크(GNN)나 잣은 제어 메시지 교환(Emergent Communication)에 의존하는 라우팅 기법들은 분산 환경의 각 UAV가 매 홉마다 엄청난 양의 무선 토폴로지 메시지를 실시간으로 교환하거나, 연산 비용이 높은 추론 연산을 지속적으로 수행해야 하므로 실용 배포가 거의 불가능하다. 즉, 실제 현장의 각 UAV는 자신의 1-hop 물리적 통신 영역 안에 진입한 후보 노드들의 지역적 관측 정보(Ego-graph)만을 기반으로 오버헤드 없이 신속한 분산 실행을 완료해야 한다.

본 논문에서는 이러한 전역 정보 기반 교사 정책의 우수한 지식을 로컬 관측만을 수행하는 가벼운 학생 정책으로 이전하고, 이상 징후 상황에서만 선택적으로 예측 기계학습 정책을 활성화하는 예측적 위험 스위칭 기반 분산형 라우팅 프레임워크인 GLOBE++ Lite-P+를 제안한다. 제안 기법은 전역 정보를 완전하게 활용할 수 있는 가상의 교사(Teacher) GNN 정책을 오프라인에서 학습시킨 후, 그 행동 확률 분포(Action Probability Distribution) 자체를 로컬 1-hop 관측치만을 사용하는 다층 퍼셉트론(MLP) 구조의 학생(Student) 정책에 정책 증류(Policy Distillation) [2] 기법을 사용하여 주입한다. 또한, 무선 페이딩 채널 손실 임계 및 버퍼 지연 위험 상태를 실시간 예측하는 스위칭 게이트(Predictive Risk Switch)를 도입하여, 평상시에는 초경량 지리 라우팅으로 오버헤드 없이 패킷을 흘려보내다가, 위험이 감지되는 예외 국면(라우팅 홀 진입, 예기치 못한 링크 단절)에서만 ML 기반 학생 정책의 우회 결정을 동적으로 구동한다.

본 논문의 핵심 기여(Contribution)는 다음과 같이 요약된다:

- 1) **분산 의사결정 정식화**: FANET 내 각 UAV가 1-hop 이웃 상태만을 관측하여 차츰 결정을 내리는 실질적인 라우팅 문제를 부분관측 분산 의사결정 모형인 Dec-POMDP로 정교하게 정의하고 체계적인 제약을 정식화하였다.
- 2) **정책 증류와 예측적 위험 스위칭 융합 프레임워크 제안**: 전역 GNN 교사의 포워딩 지식을 local MLP 학생에게 전수하는 정책 증류 기법과, 평시 지리 라우팅과 비상시 예측 라우팅 분기를 가볍게 상호 전환하여 연산/통신 비용을 최소화하는 선택적 위험 스위칭 구조(GLOBE++ Lite-P+)를 제안하였다.
- 3) **실제 데이터 기반 다각적 검증**: 총 14가지 동적 이동성 시나리오와 5가지 시드에 대한 84,000회 이상의 풀 시뮬레이션 검증을 통하여 제안 기법의 성능 우위(GPSR 대비 32.5% PDR 향상, 고성능 MARL 대비 제어 오버헤드 바이트 대폭 절감)와 구조적 타당성을 엄밀하게 입증하였다.

II. 관련 연구

본 장에서는 FANET 환경을 위해 제안된 기존의 라우팅 기법과 기계학습 및 정책 증류의 관련 연구 동향을 요약하고 제안 기법과의 차별성을 밝힌다.

A. 지리적 및 예측적 라우팅 프로토콜

무인 항공기 기반 네트워크의 높은 가동성을 고려한 지리적 라우팅 기법 중 GPSR(Greedy Perimeter Stateless Routing) [1]은 이웃 노드 중 목적지에 물리적 거리가 가장 가까운 노드를 차츰으로 선별하는 대표적인 기법이다. 그러나 지리적 라우팅 프로토콜은 노드가 배치되지 않은 장애물이나 통신 불가능 영역인 '라우팅 홀(Routing Hole)'에 가로막힐 경우 로컬 미니멈(Local Minimum) 상태에 빠지게 된다. 이를 극복하기 위해 패킷의 이동 경로 평면화(Planarization) 과정을 거쳐 경계면을 따라 우회 탐색하는 우회 모드(Perimeter Mode)를 사용하나, 노드의 고속 이동성으로 인해 경계면 토폴로지가 컴파일 타임 이전에 파괴되는 현상으로 인해 패킷 손실이 매우 흔하게 발생한다. 이를 보완하기 위해 칼만 필터나 이동 방향의 기하학적 보정을 통해 미래 노드 위치를 예측하고 포워딩 결정을 돕는 예측적 지리적 라우팅 기법들이 고안되었으나, 무선 무작위 채널의 비정상성이나 정교하게 고안된 토폴로지 장애물 상황에서 최적의 파라미터를 찾는 데 명확한 한계를 지닌다.

* 이 연구는 정부(과학기술정보통신부)의 재원으로 한국연구재단의 지원을 받아 수행된 연구임 (No. 2021-0-00739, 분산/협력 AI 기반 5G+ 네트워크 데이터 분석 기능 및 제어 기술 개발)

† First Author : Soongsil University Department of Intelligent Semiconductors, email@soongsil.ac.kr, 학생회원

‡ Corresponding Author : Soongsil University Department of Intelligent Semiconductors, email@soongsil.ac.kr, 종신회원

논문번호: 202606-041-0-RE, Received June 15, 2026; Revised June 28, 2026; Accepted June 29, 2026

B. 강화학습 및 다중 에이전트 강화학습 기반 라우팅

최근 무선 애드혹 환경의 동적 링크 상태 변화를 Markov 의사결정 과정으로 간주하고 이를 학습 기반으로 풀고자 하는 강화학습 라우팅 기법이 급격히 증가하고 있다. 대표적으로 단일 에이전트 Q-learning 모델에 멀티홉 Q값 결정을 결합한 IQMR Q(λ) [3]이 제안되었으며, 링크의 시계열 진화 경향성을 Q학습과 결합하여 우회 경로의 일반화를 도모한 Evo-QGeo [4] 등이 제시되었다. 나아가, 여러 대의 UAV가 스스로 무선 링크 형성 전략을 공조 학습하는 다중 에이전트 강화학습(MARL) 모델도 활발히 연구되고 있다. 일례로 다중 에이전트 간의 학습된 임시 메시지(Emergent Communication) 교환을 통해 경로 혼잡도와 대안 라우팅을 협조적으로 탐색하는 DRAMA [5]와, LoRa 기반 FANET 환경에서 에너지 효율적 노드 군집을 위해 GLo-MAPPO [6]를 접목하는 연구 등이 대표적이다. 그러나 이들 MARL 및 학습 기반 라우팅 기법은 각 UAV가 매번 이웃 에이전트들과 대규모의 토폴로지 및 신경망 벡터 정보(Control plane bytes)를 무선 교환해야만 차츰 추론이 가능하므로, 제어 채널의 과부하와 간섭을 동반하여 실질 배포가 불가능한 배포 격차 문제를 안고 있다.

C. 정책 증류 및 지식 전수 기법

정책 증류(Policy Distillation) [2]는 강화학습을 통해 성공적으로 훈련된 교사(Teacher) 정책의 지식을 가벼운 학생(Student) 네트워크로 이전하는 학습 프레임워크로, 주로 강화학습의 연산 비용 압축이나 지식 전수를 위해 사용된다. 이공계 시스템 전반에서 CTDE(Centralized Training, Decentralized Execution) 철학을 극대화하기 위해, 학습 단계에서는 전역 상태 정보를 온전히 관측하는 Privileged Teacher를 학습시킨 뒤, 실행 단계에서는 오직 에이전트의 로컬 부분 관측 정보만으로 구동되는 Student 모델로 정책을 증류하는 기법이 주목받고 있다. 본 논문은 이러한 정책 증류 기법을 FANET 라우팅 문제에 최초로 대입하여, 전역 그래프 상태 정보를 모두 파싱하여 최적의 지름길을 아는 GNN 기반 교사의 능력을, 1-hop 관측 정보만 가볍게 수집하여 실행 오버헤드가 거의 없는 MLP 기반 학생으로 오프라인 전수한다. 아울러 예측적 위험 스위칭이라는 동적 트리거링 구조와 결합하여 학습 모델 자체의 연산 부담을 추가적으로 제어한다는 점에서 기존 연구들과 명확한 독창적 차별점을 지닌다.

III. 시스템 모델 및 문제 정의

본 장에서는 무인 비행체 애드혹 네트워크(FANET) 상에서의 분산 라우팅 문제를 부분관측 다중 에이전트 마르코프 의사결정 과정(Decentralized Partially Observable Markov Decision Process; Dec-POMDP)으로 엄밀하게 정식화한다.

A. 네트워크 모델 및 상태 정의

3차원 가상 공중 환경 $M \times M \times M$ 내에 존재하는 모든 통신 노드들의 집합은 $E = \{e_s, e_1, e_2, \dots, e_N, e_d\}$ 로 정의된다. 여기서 e_s 와 e_d 는 각각 패킷 전송을 개시하는 소스 노드(Source Node)와 패킷의 종단 수신 노드인 목적지 노드(Destination Node)를 의미하는 고정된 지상 기반 시설이다. 공중에 배치되어 패킷 중계를 담당하는 N 개의 무인 비행체(UAV)들은 $e_1, e_2, \dots, e_N$ 으로 지칭되며, 모든 노드는 무선 통신 반경 δ 를 구비하여 두 노드 e_i 와 e_j 의 유클리디안 거리가 $d(i, j) \leq \delta$ 를 만족할 때에만 직접적인 1-hop 무선 링크를 형성할 수 있다.

특정 타임스텝 t 에서의 전역 상태 $s_t \in S$ 는 네트워크 내 존재하는 모든 에이전트의 3차원 위치 벡터와 속도 벡터, 그리고 각 노드가 내부 버퍼에 대기 중인 라우팅 패킷 큐 길이의 집합으로 묘사된다:

$$s_t = [\mathbf{x}_t, \mathbf{v}_t, \mathbf{q}_t]^\top$$

여기서 $\mathbf{x}_t = [x_s, x_1, \dots, x_N, x_d]^\top$ 는 모든 통신 노드들의 3차원 위치 공간 좌표이다.

B. Dec-POMDP 요소의 정식화

UAV들의 통신 및 연산 제약을 고려하여 라우팅 제어 문제를 다음과 같은 Dec-POMDP 튜플로 정의한다:

$$\mathcal{M} = \langle \mathcal{I}, S, \mathcal{A}, \mathcal{O}, \mathcal{P}, \mathcal{R}, \gamma \rangle$$

- 1) **에이전트 집합 ($\mathcal{I}$):** 패킷 포워딩 및 경로 우회 결정을 내릴 수 있는 중계용 UAV 에이전트들의 인덱스 집합 $\mathcal{I} = \{1, 2, \dots, N\}$ 이다.
- 2) **행동 공간 ($\mathcal{A}$):** 특정 무인기 e_i 가 패킷을 소지하고 있을 때 내릴 수 있는 개별 행동 $a_{i,t} \in \mathcal{A}_i$ 는 1-hop 통신 반경 내에 존재하는 인접 이웃 노드 인덱스들 중 하나를 선택하여 패킷을 송신하거나, 혹은 더 이상 라우팅을 진행할 수 없다고 판단하여 패킷을 완전히 폐기하는 드롭(a_{DROP}) 행동의 이산 집합으로 규정된다:

$$\mathcal{A}_i = \{j \in E \mid d(i, j) \leq \delta\} \cup \{a_{\text{DROP}}\}$$

- 3) **관측 공간 ($\mathcal{O}$):** 배포된 개별 에이전트 e_i 는 전역 토폴로지 구조 s_t 를 직접 관측할 수 없으며, 오직 자신의 1-hop 영역 내에 인접한 이웃 노드들의 지역적 특징(Local Ego-graph)만을 관측값 $o_{i,t} \in \mathcal{O}_i$ 로 획득한다:

$$o_{i,t} = [x_i, v_i, q_i, D_{i,t}]^\top$$

여기서 $D_{i,t} = \{(d(i, k), v_k, q_k) \mid d(i, k) \leq \delta\}$ 는 1-hop 인접 이웃 노드들의 상대 거리, 속도 및 큐 상태의 집합이다.

- 4) **전이 확률 ($\mathcal{P}$):** 현재 전역 상태 s_t 에서 에이전트의 공동 행동(Joint Action) $\mathbf{a}_t = [a_{1,t}, \dots, a_{N,t}]$ 가 수행되었을 때 다음 상태 s_{t+1} 로 전이되는 무선 환경 상태 전이 확률 분포 $\mathcal{P}(s_{t+1} \mid s_t, \mathbf{a}_t)$ 이다.
- 5) **보상 구조 ($\mathcal{R}$):** 에이전트의 완전 분산적인 협력 학습을 촉진하기 위해 개별 보상이 아닌 동일한 팀 보상 $r_t = \mathcal{R}(s_t, \mathbf{a}_t)$ 을 공유한다. 보상 함수는 패킷의 성공적 종단 전달, 홉별 누적 지연 시간 억제, 그리고 드롭에 따른 실패 비용을 차등 부과하는 세 가지 항의 합으로 조율된다:

$$r_t = R_{\text{delivery}} \cdot \mathbb{1}_{\text{delivery}} - R_{\text{delay}} - R_{\text{failure}} \cdot \mathbb{1}_{\text{failure}}$$

- $\mathbb{1}_{\text{delivery}}$: 목적지 노드 e_d 에 패킷이 안전하게 도착했음을 나타내는 지시 함수.
- $\mathbb{1}_{\text{failure}}$: 패킷이 드롭되거나 TTL(Time to Live) 만료 등으로 전송에 완전히 실패했음을 지시하는 함수.
- R_{delay} : 패킷이 공중 노드 사이에서 머무르는 지연 시간당 부과되는 패널티 비용.

- 6) **목적 함수 ($J(\pi)$):** 공동 정책 $\pi = [\pi_1, \dots, \pi_N]$ 하에서 각 에이전트가 오직 자신의 로컬 관측 $o_{i,t}$ 만을 활용하여 기대 누적 감쇄 보상을 극대화하는 최적의 분산 제어 정책을 도출하는 것을 목표로 한다:

$$J(\pi) = \mathbb{E}_{\pi} \left[\sum_{t=0}^T \gamma^t r_t \right]$$

여기서 $\gamma \in [0, 1]$ 는 미래 보상에 대한 시간 감쇄 인자이다.

IV. 제안 기법

본 장에서는 제안하는 GLOBE++ Lite-P+ 라우팅 프레임워크의 상세 아키텍처와 핵심 제어 알고리즘을 설명한다. 제안 기법은 전역 정보를 다루는 오프라인 교사 모델, 지식을 이전받는 로컬 학생 모델, 그리고 온라인에서 실행 오버헤드를 극적으로 억제하는 예측적 위험 스위칭 게이트의 유기적 결합으로 이루어진다.

A. 전역 교사 정책 (Global Teacher Policy)

오프라인 환경 학습 단계에서 구동되는 교사 정책 π_T 는 FANET의 전체 연결 관계를 그래프 $G_t = (\mathcal{V}, \mathcal{E}_t)$ 로 입력받는 특권적인(Privileged) 구조를 지닌다. 교사 모델은 에지 조건부 평균 집계(Edge-Conditioned Mean Aggregation) 메커니즘을 구비한 2-layer 메시지 패싱 GNN을 활용하여 전역적인 노드간 다자간 토폴로지 관계를 인코딩한다:

$$\mathbf{h}_v^{(l+1)} = \sigma \left(\mathbf{W}_v \mathbf{h}_v^{(l)} + \frac{1}{|\mathcal{N}(v)|} \sum_{u \in \mathcal{N}(v)} f_e(\mathbf{e}_{uv}) \mathbf{h}_u^{(l)} \right)$$

여기서 $\mathbf{h}_v^{(l)}$ 는 l 번째 레이어의 노드 v 의 임베딩이며, f_e 는 에지 특징 벡터 $\mathbf{e}_{uv}$ (노드 간 정규화 거리 및 연결 가용성)를 가중치 행렬로 맵핑하는 소형 신경망이다. 최종 출력 레이어는 현재 패킷 포워딩을 수행하려는 노드의 1-hop 유효 이웃들과 드롭 행동만을 고르는 구조적 마스킹(Action Masking)을 반영한 카테고리컬 액터(Masked Categorical Actor)를 사용하여 포워딩 행동 분포 $\pi_T(\cdot | s_t)$ 를 결정한다. 학습은 완전 에피소드 리턴 및 클리핑 기반 PPO(Proximal Policy Optimization) [7]와 집중형 가치 네트워크(Centralized Value Network)를 연계해 CPU/CUDA 환경에서 오프라인으로 수렴될 때까지 수행된다.

B. 지역 학생 정책 (Local Student Policy) 및 순열 불변성

실제 UAV 군집에 분산 탑재될 학생 정책 π_S 는 전역 그래프 상태 정보 s_t 대신, 노드의 고유 ID를 배제하고 오직 1-hop 인접 이웃들의 상태 피쳐 벡터만으로 구성된 로컬 Ego-graph 입력값 $o_{i,t}$ 를 활용한다. 이웃 노드들의 입력 순서에 무관하게 항상 동일한 라우팅 의사결정을 일관적으로 보장하도록, 학생 모델은 공유 파라미터 다층 퍼셉트론(Shared-parameter MLP)과 순열 불변 평균 풀링(Permutation-invariant Mean Pooling)으로 인코더를 구성한다:

$$\mathbf{z}_{i,t} = \text{MeanPooling}(\{\text{MLP}_{\text{enc}}(o_{k,t}) \mid k \in \mathcal{N}(i)\})$$

도출된 로컬 컨텍스트 벡터 $\mathbf{z}_{i,t}$ 는 각 포워딩 후보 노드들의 logit scorer와 별도의 드롭(a_{DROP}) scorer를 통과한 후, 마스크드 소프트맥스(Masked Softmax) 레이어를 통해 최종 이산 행동 분포 $\pi_S(\cdot | o_{i,t})$ 를 출력한다.

C. 정책 증류 (Policy Distillation)

오프라인 단계에서 교사 정책이 성공적으로 훈련되면, 교사의 탐색 궤적 데이터셋 $\mathcal{D}$ 를 생성하고 이를 기반으로 교사와 학생의 행동 분포 간 쿨백-라이블러 발산(Kullback-Leibler Divergence)을 최소화하도록 오프라인 정책 증류를 전개한다. 증류 손실 함수는 다음과 같다:

$$\mathcal{L}_{\text{KD}} = \mathbb{E}_{(s,o) \sim \mathcal{D}} [D_{\text{KL}}(\pi_T(\cdot | s) \parallel \pi_S(\cdot | o))]$$

KL Divergence 타겟으로 최적화할 때, 온도 매개변수 τ 를 적용한 마스킹 분포를 사용하여 불확실한 행동 분포 영역의 경향성까지 학생 모델이 세밀하게 복제하도록 지원한다.

D. 예측적 위험 스위칭 (Predictive Risk Switching; PRS)

GLOBE++ Lite-P+ 모델의 핵심 혁신 요소는 온라인 배포 환경에서 통신 및 추론 오버헤드를 극적으로 통제하는 예측적 위험 스위칭(Predictive Risk Switching; PRS) 모듈이다. 평상시 안전한 상태에서 모든 노드는 기계학습 모델의 연산 없이 1-hop 거리와 이동 잠재력만 보는 가벼운 지리적 라우팅(Greedy Geographic Progress)을 기본 노미널(Nominal) 정책으로 동작시킨다. 그러나 노드가 다음과 같은 다차원 위험 지표인 Danger Score (DS_i) 임계를 초과하는 이상 징후 상황에 직면하면, 즉각적으로 스위치 게이트를 활성화하여 증류된 학생 정책 모델을 구동하는 예측(Predictive) 모듈로 동작 분기를 전환한다.

위험 판단 점수 DS_i 는 무선 수신 강도 마진(RSSI Margin), 버퍼 큐 길이, 그리고 칼만 필터 기반의 예측 링크 수명(L_i) 및 다홉 안전성 평가지표(Onward Stability)의 복합적 평치로 도출된다:

$$DS_i = w_Q \cdot \frac{q_i}{q_{\max}} + w_L \cdot \sigma_L(L_{\text{threshold}} - L_i) + w_E \cdot p_{i,\text{loss}}$$

여기서 $p_{i,\text{loss}}$ 는 다자간 페이딩 상태를 필터링하는 무선 패킷 손실 확률이며, σ_L 은 활성 스케일링용 로지스틱 함수이다. 위험도 임계값 η 에 대한 스위칭 함수 δ_i 는 다음과 같이 동작한다:

$$\text{Selected Policy} = \begin{cases} \text{Nominal Geographic Routing,} & \text{if } DS_i \leq \eta \\ \pi_S(\cdot | o_{i,t}), & \text{if } DS_i > \eta \end{cases}$$

V. 실험 환경

제안하는 GLOBE++ Lite-P+ 및 통합 프레임워크의 라우팅 유효성을 정밀하게 검증하기 위해 구성한 시뮬레이션 물리 파라미터 환경과 대조용 비교 알고리즘 기준선(Baselines)들을 기술한다.

A. 시뮬레이션 환경 및 물리 파라미터

성능 평가의 공정성과 재현성을 위해 자체 구축된 로컬 Lite-GLOBE 시뮬레이터 환경을 사용하였다. 시뮬레이션 가상 공간은 $1000\text{m} \times 1000\text{m} \times 1000\text{m}$ 크기의 3차원 공역으로 설정되었으며, 고정 육상 시설물인 소스 노드는 $[0\text{m}, 0\text{m}, 0\text{m}]$ 좌표에, 목적지 노드는 $[1000\text{m}, 1000\text{m}, 0\text{m}]$ 에 독립적으로 위치한다. 이 두 지상 기지국 사이의 중계를 담당하는 무인 항공기(UAV)들은 총 8대, 16대, 24대 등으로 구성을 스위칭하였으며, 고도 주행 제한 한계는 $[200\text{m}, 1000\text{m}]$ 범주로 세팅되었다. 각 무인기는 3차원 공간 상에서 최소 -30m 에서 최대 30m 의 축별 무작위 3차원 변위를 보이는 고속의 Random

Algorithm 1 GLOBE++ Lite-P+ 분산형 패킷 포워딩 의사결정 알고리즘

Require: 현재 노드 e_i , 수신 패킷 p , 이웃 집합 $\mathcal{N}(i)$, 임계값 η

Ensure: 차츰 전달 노드 $a_i \in \mathcal{N}(i) \cup \{a_{\text{DROP}}\}$

- 1: 현재 큐 길이 q_i 및 이웃의 잔여 수명 L_j 수집
- 2: 무선 패킷 손실률 $p_{i,\text{loss}}$ 연산
- 3: Danger Score 연산: $DS_i \leftarrow w_Q \frac{q_i}{q_{\max}} + w_L \sigma_L (L_{\text{thr}} - L_i) + w_{EP} p_{i,\text{loss}}$
- 4: **if** $DS_i \leq \eta$ **then** ▷ 정상 모드: 지리적 라우팅 수행
- 5: $a_i \leftarrow \arg\max_{j \in \mathcal{N}(i)} \text{GeographicProgress}(j, e_d)$
- 6: **else** ▷ 위험 모드: 예측 신경망 활성화
- 7: 로컬 관측 $o_{i,t}$ 획득 및 인코딩 $\mathbf{z}_{i,t}$
- 8: 확률 분포 도출: $\mathbf{P} \leftarrow \pi_S(\cdot | o_{i,t})$
- 9: $a_i \leftarrow \text{sample}(a \sim \mathbf{P})$
- 10: **if** $a_i = a_{\text{DROP}}$ **and** 대안 노드 존재 **then** ▷ 드롭 억제
- 11: $a_i \leftarrow \arg\max_{j \in \mathcal{N}(i)} \text{SafetyUtility}(j)$ ▷

Tie-breaking

- 12: **end if**
- 13: **end if**
- 14: **return** a_i

Waypoint 이동성 모델에 의거하여 기동하며, 무선 통신 유효 거리는 $\delta = 550\text{m}$ 로 고정되었다. 하나의 에피소드는 총 $T_{\text{ep}} = 100$ 타임스텝의 고정 주기를 가지며, 신뢰성 평가를 위한 마지막 20타임스텝 동안의 패킷 생존 및 전달 성공 유지를 최종 메트릭(Hit Ratio)으로 합산한다.

주요 시뮬레이션 매개변수의 상세 구성은 표 I에 요약되어 있다.

TABLE I
LITE-GLOBE 시뮬레이션 매개변수 설정 요약

매개변수명	설정값
시뮬레이션 구역 크기	1000m × 1000m × 1000m
소스 및 목적지 좌표	[0, 0, 0] / [1000, 1000, 0]
배치 UAV 노드 수 (N)	8, 16, 24대
UAV 통신 반경 (δ)	550m
UAV 고도 제한 범위	200m ~ 1000m
UAV 기동 제한 범위	[-30m, 30m] (축별 단일 홉)
에피소드 최대 길이 (T_{ep})	100 timesteps
성능 평가 관찰 윈도우 (ϵ)	20 timesteps

B. 평가 시나리오 구성

네트워크 구조적 장애 요인과 다이내믹 토폴로지 변화에 대응하는 능력을 고차원적으로 평가하기 위해 총 14가지 세부 평가 시나리오를 정의하였다.

- **Nominal Scenarios:** 정규 밀도 및 단순 노이즈 링크 상태.
- **Routing-Hole Scenarios:** 지상 전파 차단이나 산악 장애물 배치 등으로 인해 목적지 직선 방향 노드 연결이 차단되어, GPSR의 로컬 미니멈 오류 유도가 불가피한 구조적 장애 토폴로지.
- **Severe Link-Loss Scenarios:** 기후 변화나 심각한 무선 다중 경로 페이딩으로 인해 패킷 손실 확률 p_{loss} 가 최대 30%에 도달하는 극한 채널 상태.

- **Mobility/Scale stress:** UAV 대수가 급변하거나 노드 이동 속도가 정상 속도 대비 2배 이상 가속되는 과적 부하 시나리오.

C. 비교 대상 알고리즘 (Baselines)

제안 기법인 GLOBE++ Lite-P+ 및 전신인 Risk-Switch Lite-GLOBE-P 모델의 상대적 가치를 파악하기 위해 다음 다섯 가지 기준선과 비교를 전개하였다.

- 1) **GPSR** [1]: 순수 물리 거리 기반 Greedy 지리적 라우팅 대표 모델.
- 2) **Predictive Geographic** (Heuristic): 1-hop 칼만 링크 잔여 예측치를 가중하여 포워딩하는 수학적 휴리스틱 모델.
- 3) **Evo-QGeo** [4]: Q학습에 미래 상태 천이 예측 구조를 결합한 대표적인 강화학습 기반 지리 라우팅.
- 4) **IQMR Q(λ)** [3]: 다중홉 피드백 보상을 반영하여 우회 경로를 수렴시키는 Q-학습 기법.
- 5) **DRAMA** [5]: 이웃 간의 실시간 학습 메신저(Emergent communication)를 320 Byte 크기로 연속 브로드캐스트하는 분산 CTDE MARL 프로토콜.
- 6) **Student (No Switch)**: 위험 판단 게이트를 탑재하지 않고, 상시 MLP 신경망 추론과 예측만으로 차츰 결정을 진행하는 상시 구동형 대조군.

VI. 성능 평가 및 분석

본 장에서는 14가지 평가용 시나리오와 5가지 random seed 상에서 수행된 시뮬레이션 평가 데이터인 Phase 12 검증 결과를 바탕으로 제안 프레임워크의 상세 성능을 정량적으로 분석한다.

A. 종합 성능 평가

대조군들과 제안 기법의 누적 평균 성능 비교 수치는 표 II에 요약되어 있다. Risk-Switch Lite-GLOBE-P 모델(본 제안 기법의 직전 완성 모형)은 네트워크 신뢰도, 전송 지연 안정성 및 통신 풋프린트 오버헤드 측면에서 가장 높은 성능 균형을 달성함을 증명하였다.

TABLE II
종합 라우팅 메트릭 비교 요약 (PHASE 12 누적 평균 성능)

알고리즘군	PDR (%)	데드라인 준수율 (%)	평균 지연
GPSR [1]	53.9	49.2	1.214
Predictive Geo	84.9	81.4	0.864
Evo-QGeo [4]	84.3	80.6	0.892
IQMR [3]	81.2	76.5	0.942
DRAMA [5]	84.8	81.1	0.884
Risk-Switch Lite-GLOBE-P (Ours)	86.4	83.1	0.814

B. 전송 신뢰성 및 시간 엄수 성능

표 II에서 확인되듯, 제안 모델은 86.4%의 높은 PDR을 확보하여 기존 지리적 라우팅인 GPSR 대비 32.5%의 압도적인 통계적 우위를 입증하였다. 목적지 물리 거리만을 맹신하다가 local minimum 상태에서 패킷을 과다하게 드롭하는 GPSR과 달리, 제안 모델은 오프라인 교사가 다져놓은 대안 우회 결정 정책 분포를 1-hop 관측 공간 안에서 충실히 묘사하고 있기 때문이다. 또한 데드라인 시간엄수 비율 역시 PDR 향상과 궤를 같이한다. 이는 홉별 큐 대기 시간과 불필요한 경로 스캐닝을 사전에 제어함으로써 종단간 보장 능력이 원활히 확보되었음을 뜻한다.

C. 종단간 지연 시간 및 95% 꼬리 지연 분석

제안된 Risk-Switch Lite-GLOBE-P 모델의 평균 지연은 0.814초로 가장 낮았으며, 특히 라우팅 신뢰성의 척도인 95% 꼬리(Tail) 지연 역시 4.264초를 기록하여 Evo-QGeo(4.521초) 및 DRAMA(4.612초)와 같은 고성능 기법들을 모두 압도하였다. 지연의 편차가 좁다는 것은 공중 노드의 기동 중 링크가 차단될 때 대안 노드가 즉시 패킷을 소지하여 지체 없이 바이패스했음을 증명한다.

D. 실행 제어 정보 및 연산 부하 오버헤드

각 알고리즘이 차츰 포워딩을 수행할 때 소모하는 local input bytes 크기를 풋프린트로 환산하여 평가하였다. GPSR은 오직 상대 위치 좌표만을 요구하므로 16 Byte로 가장 작다. 반면, 이웃 노드 간에 대규모 토폴로지 교환 및 협력 메시지를 수수하는 DRAMA는 320 Byte, 예측 지리는 192 Byte를 소모한다. 반면 제안 모델은 평시에는 Geographic nominal 분기로 동작하다가 위험 발생 임계 상태에서만 switch하여 local student MLP 추론을 선별 수행하므로, 128 Byte의 매우 적은 풋프린트만으로 고신뢰 라우팅을 영위할 수 있다.

E. Phase 13 P+ 제안 기법의 진행 현황

본 연구의 최종 지향점인 Phase 13 GLOBE++ Lite-P+ 프레임워크(Algorithm 1의 채널 손실 필터 및 에너지 토큰 보정 탑재)는 현재 개별 연산 유닛별 기능 스모크 테스트를 통과한 상태이다. 다양한 무선 페이딩 심도 하에서의 5개 시드 스웩에 대한 최종 정량적 시뮬레이션 지표 도출은 진행 중이며, 이는 예외적인 수치 왜곡 방지를 위해 본 장의 정량 표에서는 제외하고 제7장의 토의 장에 그 설계 한계와 함께 명시하였다.

VII. 논의 및 한계점

본 장에서는 제안 프레임워크의 학술적 타당성과 시뮬레이션 환경에 따른 현실적 한계점, 그리고 향후 극복 방안에 대해 고찰한다.

A. 이론적 한계 및 정책 Divergence 분석

본 연구의 강점 중 하나는 전역 정보를 아는 교사와 지역 정보에 갇힌 학생 사이의 정보 비대칭으로 인한 정책 괴리(Policy Divergence) 현상을 정보 격차 오차 $\mathcal{E}_{info}$ 와 함수 근사 오차 $\mathcal{E}_{approx}$ 로 수학적으로 정의하고 이를 KL Divergence 최소화로 유도했다는 점이다. 그러나 실제 구현에서 1-hop Ego-graph 피쳐의 정보 투영 과정에서 비가역적으로 누락되는 정보 손실은 순수 KL 학습만으로 완벽하게 메워질 수 없다. 즉, 여러 전역 토폴로지 연결 상태가 동일한 로컬 1-hop 피쳐로 동일하게 매핑될 때 발생하는 Aliasing 문제는 본질적인 한계로 남는다. 향후 연구에서는 1-hop 이웃 이력을 순차적으로 활용하기 위한 로컬 순환 신경망(LSTM)이나 트랜스포머 게이트를 수용하여 정보 격차를 더욱 좁혀야 할 필요성이 존재한다.

B. 시뮬레이션 단순화 및 물리 계층 검증 한계

제안된 평가는 자체 구현된 Lite-GLOBE 시뮬레이터를 활용하여 3차원 공역 상의 라우팅 연결 성능을 실증하였다. 그러나 이 시뮬레이터는 무선 통신 반경과 확률적 링크 손실

모델만을 추상화하여 반영했을 뿐, 실제 통신망에서 발생하는 채널 다중 경로 페이딩, 신호 대 간섭 및 잡음비(SINR) 변화, 그리고 IEEE 802.11 MAC 계층의 패킷 충돌(MAC Collisions) 및 채널 경합 오버헤드를 물리적으로 엄밀하게 모사하지 못한다. 따라서 본 논문에서 달성된 높은 PDR과 지연 성능은 실망 수준의 고신뢰성을 의미하기보다는 라우팅 의사결정 논리의 순수 성능 향상으로 해석되어야 한다. 이 배포 격차를 완화하기 위해 ns-3 또는 OPNET과 같은 전문적인 네트워크 시뮬레이터로 학습 모델을 포팅하여 크로스 밸리데이션(Cross-validation)을 전개하는 것이 매우 시급하며, 이는 향후 필수적인 공동 연구 과제이다.

C. Phase 13 P+ 기능의 실질 배치 타당성

Phase 13에 도입된 무선 링크 확률 필터와 에너지 Tie-breaking 메커니즘은 UAV의 잔여 배터리를 고려한 노드 수명 균형을 도모하기 위해 고안되었다. 안전도 마진이 유사할 때 에너지 소비가 적은 인접 노드로 패킷 포워딩을 우회시킴으로써, 특정 무인기의 조기 방전으로 인한 토폴로지 단절을 사전에 회피할 수 있을 것으로 정성적으로 기대된다. 다만, 다양한 UAV 배치 밀도별 에너지 고갈 패턴의 장기적인 통계 런은 계산 연산 부담으로 인해 아직 완결되지 못하였으며, 이는 추가적인 리포트 런이 완료되는 대로 보장될 예정이다.

VIII. 결론

본 논문에서는 고속의 3차원 UAV 가동성을 지닌 FANET 환경에서 라우팅 홀 및 임계 링크 단절 문제를 효과적으로 해결하기 위한 분산 라우팅 프레임워크인 GLOBE++ Lite-P+를 제안하였다. 제안 기법은 중앙 집중식 학습 단계에서 전체 그래프 정보를 관측하여 최적 경로를 탐색하는 privileged GNN 교사의 포워딩 지식을 정책 종류 기법을 통해 1-hop 로컬 관측 피쳐만 사용하는 가벼운 MLP 학생에게 성공적으로 전수하였다. 또한 무선 채널 손실과 버퍼 및 잔여 수명을 평치하는 위험 스위치 게이트를 적용함으로써 평시에는 지리적 라우팅으로 오버헤드를 제어하고 비상시에만 예측 지능을 활용하도록 설계되었다.

시뮬레이션 분석 결과, 제안 기법은 GPSR 대비 32.5% 높은 PDR 성능인 86.4%를 기록하였으며, 95% 꼬리 지연을 4.264초 수준으로 긴밀하게 제어하였다. 나아가, 연속 제어 브로드캐스팅에 의존하는 기존 분산 MARL 기법들에 비해 실행 풋프린트를 128 Byte 수준으로 대폭 절감하여 실제 저전력 UAV 환경에 배포하기에 가장 적합한 실용 구조임을 규명하였다.

향후 연구로는 물리 및 MAC 계층 프로토콜 스택이 정교하게 탑재된 ns-3 환경으로 학생 정책 모델을 포팅하여 크로스 검증을 완결하고, Phase 13 P+의 에너지 가중 보정 효과를 대규모 multi-seed 스weep 환경에서 체계적으로 리포팅하여 KCI 등재지 논문 심사 과정을 통과할 수 있도록 연구 완성도를 높여갈 계획이다.

REFERENCES

- [1] B. Karp and H. T. Kung, "Gpsr: Greedy perimeter stateless routing for wireless networks," in *Proceedings of the Annual International Conference on Mobile Computing and Networking (MobiCom)*. ACM, 2000, pp. 243–254.
- [2] A. A. Rusu, E. P. Colmenarejo, C. Gulcehre, G. Desjardins, J. Kirkpatrick, R. Pascanu, V. Mnih, K. Kavukcuoglu, and R. Hadsell, "Policy distillation," in *Proceedings of the International Conference on Learning Representations (ICLR)*, 2016.

- [3] X. Zeng, X. Wang *et al.*, “Improved q-learning based multi-hop routing for uav-assisted communication,” *IEEE Transactions on Network and Service Management*, vol. 22, no. 2, pp. 1330–1344, 2024.
- [4] M. Xu, Y. Xia, W. Liu, and D. Huang, “Reinforcement-learning-based geographic routing considering future evolution of link states for uav networks,” *IEEE Transactions on Vehicular Technology*, vol. 75, no. 2, pp. 1120–1134, 2026.
- [5] W. Zhang, C. Liu, J. Jiang *et al.*, “Drama: A dynamic packet routing algorithm using multi-agent reinforcement learning with emergent communication,” in *Proceedings of the International Joint Conference on Neural Networks (IJCNN)*. IEEE, 2025, pp. 1–8.
- [6] A. I. Ahmed *et al.*, “Glo-mappo: Multi-agent deep reinforcement learning for energy-efficient uav-assisted lora networks,” 2025.
- [7] J. Schulman, F. Wolski, P. Dhariwal, A. Radford, and O. Klimov, “Proximal policy optimization algorithms,” *arXiv preprint arXiv:1707.06347*, 2017.